

# Lecture 1 - Introduction & Preliminaries

赵尉辰

南开大学 统计与数据科学学院

# 目录

- 1 课程概况
- 2 概率空间
- 3 随机变量
- 4 数学期望
- 5 一些概率工具：矩母函数、概率不等式、极限定理
- 6 随机过程

# 目录

- 1 课程概况
- 2 概率空间
- 3 随机变量
- 4 数学期望
- 5 一些概率工具：矩母函数、概率不等式、极限定理
- 6 随机过程

## 本人信息

- 授课老师：赵尉辰；
- 电子邮箱：zhaoweichen@nankai.edu.cn；
- 个人主页：  
<https://my.nankai.edu.cn/stat/zwc/list.htm>
- 研究领域：  
图深度学习方法及应用；  
随机算法：采样、随机优化、扩散模型；  
深度学习理论。

# 课程信息

- 课程主页:

<https://weichenzhao1996.github.io/WeichenZhao.io/STAT0008-2025.html>

智慧小雅

- 教材: Sheldon M. Ross, Stochastic Processes. 2nd Edition

Sheldon M. Ross 著, 龚光鲁 译, 随机过程(第2版)

参考书:

1. James R. Norris, Markov chains.
2. 陆大綸 张颢, 随机过程及其应用(第2版)

- 教学方式: 板书+Slides

- 考核方式:

- 5次平时作业 30% (纸质版, latex/手写);
- 出勤 10% (签到);
- 期末考试 60% (出7-8道题, 选取得分最高的5道题记录成绩).

# 课程简介

- 随机过程导论/应用随机过程;
- 预备课程: 初等概率论、(实分析、泛函分析)
- 主要内容:
  - 概率论基础
  - Poisson过程
  - Markov链
  - 连续时间Markov链 (排队论)
  - Markov过程\* (状态连续)
  - 随机过程在数据科学中的应用 (MCMC算法, 模拟退火, Markov决策过程\*)
- 后续课程: 随机分析

# 目录

- 1 课程概况
- 2 概率空间**
- 3 随机变量
- 4 数学期望
- 5 一些概率工具：矩母函数、概率不等式、极限定理
- 6 随机过程

# 样本空间

概率论是研究随机现象确定性规律的理论。为了使用数学工具，我们首先要建立随机现象的数学模型。

在概率论中，我们假定**随机试验**(random trial)可以在相同条件下重复地进行，每次试验的结果可能不止一个，并且能事先确定试验的所有可能结果，但每次试验的结果事先又不可预测。这样一组定义明确的可能结果，称为样本空间。

## 定义 1 (样本空间Sample Space)

把随机试验每一个可能的结果称为一个样本点 (*sample point*), 通常用  $\omega$  表示, 所有可能的结果组成的集合称为**样本空间**(*sample space*), 通常用  $\Omega$ 表示。

考虑先后掷两次硬币可能出现的结果是：(正, 正)(正, 反)(反, 正)(反, 反)，把这四个结果作为样本点构成这个随机试验样本空间。



# 事件

事实上, 我们感兴趣的是试验中出现的一些事, 比如, 先后掷两次硬币这个随机试验中我们可能感兴趣 “两次出现的结果相同” 这件事, 它是指 (正, 正)(反, 反) 这两个样本点之一出现。这些 “事” 是样本点的集合, 称为事件。

## 定义 2 (事件Event)

**事件** 定义为样本点的某个集合, 称某事件发生当且仅当它所包含的某个样本点出现。

我们把样本空间 $\Omega$ 本身也作为一个事件。每次试验必然有 $\Omega$ 中的某个样本点出现, 即 $\Omega$ 必然发生。因此, 我们称 $\Omega$ 为必然事件(certain event)。我们把空集 $\emptyset$ 也作为一个事件, 每次试验中, 它都不发生, 因此, 称为 $\emptyset$ 为不可能事件(impossible event)。

# 事件

我们需要能够用简单的事件来刻画复杂的事件，这是由集合的运算实现的。

- 我们称事件 $A$ 发生意味着事件 $B$ 发生, 如果 $A \subset B$ .  
 $A = B \iff A \subset B$  且  $B \subset A$ ;
- 由所有不包含在事件 $A$ 中的样本点所组成的事件称为事件 $A$ 的对立事件, 记为 $A^c$ ;
- 用 $A \cap B$  or  $AB$ 表示 $A$ 和 $B$ 都发生;
- 用 $A \cup B$ 表示事件 $A$ 和 $B$ 至少有一个发生;
- 用 $A \setminus B$ 表示事件 $A$ 发生, 但是 $B$ 不发生;

# 事件域

如果我们对事件 $A$ 感兴趣，那么我们应该知道与 $A$ 相关的事件，也就是我们需要找出通过集合运算得到的事件。所有这些事件的集合，称为事件域。

## 定义 3 (事件域Event field)

$\mathcal{F}$ 是由样本空间 $\Omega$ 的一些子集组成的集合，称为事件域 (event field) 如果满足：

- (1) 非空  $\mathcal{F} \neq \emptyset$ ;
- (2) 对补运算封闭  $A \in \mathcal{F} \implies A^c \in \mathcal{F}$ ;
- (3) 对可列并运算封闭  $A_n \in \mathcal{F}, n = 1, 2, \dots \implies \cup_{n=1}^{\infty} A_n \in \mathcal{F}$ .

# 事件域

事件与事件域是紧密联系的，在表述事件时，必须明确是在哪个事件域中。

## 例 1

考虑有两个正方形盒子，被分成四个区域，其中盒子1盒盖是完全透明的，盒子2的乙和丁区域是不透明的。考虑盒子中均有一个小球可以滚动，随意晃动盒子，小球停止运动后，随机地停留在这四块区域中的某块中(假设处于理想状态，不考虑小球处于分割线)。




图 1




图 2

# 事件域

这两个随机试验的样本空间均为  $\Omega = \{\text{甲}, \text{乙}, \text{丙}, \text{丁}\}$ 。

但是试验1的事件域  $\mathcal{F}_1$  为  $\Omega$  的全体子集组成的集合，其中共有 16 个事件。对于试验1的每一个结果  $\omega$ ，对于  $\Omega$  的每个子集  $A$ ，总能判断出  $\omega$  是否属于  $A$ ，也就是说每次实验后，总能知道事件  $A$  是否发生。

试验2的事件域

$$\mathcal{F}_2 = \{\Omega, \emptyset, \{\text{甲}\}, \{\text{丙}\}, \{\text{甲}, \text{丙}\}, \{\text{乙}, \text{丁}\}, \{\text{甲}, \text{乙}, \text{丁}\}, \{\text{丙}, \text{乙}, \text{丁}\}\},$$

只包含了 8 个事件。对于试验的某些结果，虽然可以看到小球停留在不透明的区域，但是我们不能判断此时小球是否在“乙”区域，也就是说，不知道  $\{\text{乙}\}$  是否发生了。因此，对于事件域  $\mathcal{F}_2$ ， $\Omega$  的子集  $\{\text{乙}\}$  就不是事件。同样的， $\{\text{丁}\}$  和  $\{\text{甲}, \text{乙}\}$  等也不是事件。

# 概率

搞清楚了我们感兴趣的事件的集合，我们现在需要量化它发生的可能性，这就需要引入概率。

## 定义 4 (概率Probability measure)

称集合函数 $P$ 是事件域 $\mathcal{F}$ 上的**概率(Probability measure)**，如果

- (1) 非负性:  $P(E) \geq 0, \forall E \in \mathcal{F}$ ;
- (2)  $P(\emptyset) = 0, P(\Omega) = 1$ ;
- (3) 可列可加性: 对于不相交的集合(互斥事件) $E_n \in \mathcal{F}, n = 1, 2, \dots$

$$P\left(\bigcup_{n=1}^{\infty} E_n\right) = \sum_{n=1}^{\infty} P(E_n).$$

# 概率的基本性质

- 若  $E \subset F$ , 则  $P(E) \leq P(F)$ . (单调性 monotonicity)
- $P(E^c) = 1 - P(E)$ .
- $P(\bigcup_i E_i) \leq \sum_i P(E_i)$  (次可加性 subadditivity/ Boole's inequality)

# 概率的连续性

- 对于一个递增事件序列  $\{E_n, n \geq 1\}$ , 即,  $E_1 \subset E_2 \subset \cdots$ , 定义其极限事件为

$$\lim_{n \rightarrow \infty} E_n \triangleq \bigcup_{i=1}^{\infty} E_i.$$

- 对于一个递减事件序列  $\{E_n, n \geq 1\}$ , 即,  $E_1 \supset E_2 \supset \cdots$ , 定义其极限事件为

$$\lim_{n \rightarrow \infty} E_n \triangleq \bigcap_{i=1}^{\infty} E_i.$$

## 命题 1

如果  $\{E_n, n \geq 1\}$  是一个递增或者递减序列, 那么

$$\lim_{n \rightarrow \infty} P(E_n) = P\left(\lim_{n \rightarrow \infty} E_n\right)$$



## Borel-Cantelli 引理

设  $E_1, E_2, \dots$  是一个事件序列, 定义:

$$\limsup_{i \rightarrow \infty} E_i \triangleq \bigcap_{n=1}^{\infty} \bigcup_{i=n}^{\infty} E_i = \{\text{无穷多个 } E_i \text{ 发生}\} = \{\omega \in \Omega : \forall n, \exists i \geq n, \text{ 使 } \omega \in E_i\}$$

若有无穷多个  $E_i$  发生, 则对每个  $n$ ,  $\bigcup_{i=n}^{\infty} E_i$  都发生, 从而  $\bigcap_{n=1}^{\infty} \bigcup_{i=n}^{\infty} E_i$  发生。

另一方面, 如果事件  $\bigcap_{n=1}^{\infty} \bigcup_{i=n}^{\infty} E_i$  发生, 则对所有  $n$ ,  $\bigcup_{i=n}^{\infty} E_i$  发生, 从而对所有  $n$ , 至少有个  $i \geq n$ , 使得  $E_i$  发生, 因此有无穷多个  $E_i$  发生。

思考.<sup>1</sup>  $\liminf$  情形:

$$\liminf_{i \rightarrow \infty} E_i = \bigcup_{n=1}^{\infty} \bigcap_{i=n}^{\infty} E_i = \{\text{至多有限多个 } E_i \text{ 不发生}\} = \{\omega \in \Omega : \exists n, \forall i \geq n, \omega \in E_i\}$$

<sup>1</sup>更多集合论的内容参考: 严加安, 《测度论讲义》, 1.1节

# Borel-Cantelli 引理

## 命题 2 (Borel-Cantelli 引理)

若  $\sum_{i=1}^{\infty} P(E_i) < \infty$ , 那么

$$P(\text{无穷多个 } E_i \text{ 发生}) = 0.$$

**Proof.** 注意到  $\bigcup_{i=n}^{\infty} E_i, n \geq 1$  是递减的事件序列, 由概率的连续性:

$$\begin{aligned} P\left(\bigcap_{n=1}^{\infty} \bigcup_{i=n}^{\infty} E_i\right) &= P\left(\lim_{n \rightarrow \infty} \bigcup_{i=n}^{\infty} E_i\right) = \lim_{n \rightarrow \infty} P\left(\bigcup_{i=n}^{\infty} E_i\right) \\ &\leq \lim_{n \rightarrow \infty} \sum_{i=n}^{\infty} P(E_i) = 0. \end{aligned}$$

最后一个等号成立是因为:  $\sum_{i=1}^{\infty} P(E_i) < \infty$ .



# Borel-Cantelli 引理

## 命题 3 (Borel-Cantelli 引理 II)

设  $E_1, E_2, \dots$  是一个独立事件序列, 若  $\sum_{i=1}^{\infty} P(E_i) = \infty$ , 那么

$$P(\text{无穷多个 } E_i \text{ 发生}) = 1.$$

**Proof.** 对于任意  $n < m < \infty$ , 注意到  $1 - x \leq e^{-x}$ , 于是

$$\begin{aligned} P\left(\bigcap_{i=n}^m E_i^c\right) &= \prod_{i=n}^m P(E_i^c) \quad (\text{由独立性}) \\ &= \prod_{i=n}^m (1 - P(E_i)) \leq \prod_{i=n}^m \exp(-P(E_i)) = \exp\left[-\sum_{i=n}^m P(E_i)\right] \xrightarrow{m \rightarrow \infty} 0. \end{aligned}$$

因此,  $P(\cup_{i=n}^m E_i) \rightarrow 1$  as  $m \rightarrow \infty$ ,  $P(\cup_{i=n}^{\infty} E_i) = 1$  对任意  $n$  成立. 那么

$$P(\text{无穷多个 } E_i \text{ 发生}) = P\left(\lim_{n \rightarrow \infty} \bigcup_{i=n}^{\infty} E_i\right) = \lim_{n \rightarrow \infty} P\left(\bigcup_{i=n}^{\infty} E_i\right) = 1.$$

## Borel-Cantelli 引理

### 例 2

设  $X_1, X_2, \dots$  独立且满足

$$P(X_n = 0) = \frac{1}{n}, \quad P(X_n = 1) = 1 - \frac{1}{n}, \quad n \geq 1$$

考虑事件  $E_n = \{X_n = 0\}$ , 由于  $\sum_{n=1}^{\infty} P(E_n) = \sum_{n=1}^{\infty} \frac{1}{n} = \infty$ , 由 *Borel-Cantelli* 引理 II,

$$P(\text{无穷多个 } E_n \text{ 发生}) = 1.$$

我们是否可以说, 以概率1,  $\lim_{n \rightarrow \infty} X_n = 0$ ?

答案是否定的, 由于  $\sum_{n=1}^{\infty} P(E_n^c) = \sum_{n=1}^{\infty} (1 - \frac{1}{n}) = \infty$ , 由 *Borel-Cantelli* 引理 II,

$$P(\text{无穷多个 } E_n^c \text{ 发生}) = 1.$$

于是以概率1,  $n \rightarrow \infty$ ,  $X_n$  没有极限值。

# 概率空间

总结一下，我们需要三个部分来建立随机现象的数学模型：

- 随机试验的样本空间 $\Omega$ ，它是包含了这个试验所有可能结果的非空集合；
- 事件域 $\mathcal{F}$ ，它是我们感兴趣的事件，以及这些事件通过运算得到的事件的全体；
- 概率 $P$ ，它量化了事件发生的可能性。

定义 5 (概率空间Probability space)

概率空间(*Probability space*)是一个数学三元组 $(\Omega, \mathcal{F}, P)$ .

## 补充概念

在测度论中，满足事件域定义的集合族 $\mathcal{F}$ 也称为 $\sigma$ -代数( $\sigma$ -algebra)或者 $\sigma$ -域。 $(\Omega, \mathcal{F})$ 称为一个可测空间(measurable space)。可以定义 $\mathcal{F}$ 上的集合函数 $\mu$ 满足非负性和可列可加性，称为 $\mathcal{F}$ 上的测度(measure)， $(\Omega, \mathcal{F}, \mu)$ 称为测度空间。概率空间是一类特殊的测度空间。

**生成 $\sigma$ -代数**：设 $\mathcal{C}$ 是 $\Omega$ 的非空集族，称 $\mathcal{S}$ 是 $\mathcal{C}$ 生成的 $\sigma$ -代数，如果

(1)  $\mathcal{C} \subset \mathcal{S}$ ；(2) 对任意 $\Omega$ 上的 $\sigma$ -代数 $\tilde{\mathcal{S}}$ ，如果 $\mathcal{C} \subset \tilde{\mathcal{S}}$ ，那么 $\mathcal{S} \subset \tilde{\mathcal{S}}$ 。

即 $\mathcal{S}$ 是包含 $\mathcal{C}$ 的最小 $\sigma$ -代数，记为 $\sigma(\mathcal{C})$ 。对任意 $\mathcal{C}$ ， $\sigma(\mathcal{C})$ 是存在唯一的。

我们介绍 $\mathbb{R}$ 上一类常见的 $\sigma$ -代数：**Borel  $\sigma$ -代数**。

记 $\mathbb{R}$ 上左开右闭区间组成的集合族为

$$\mathcal{C} = \{(a, b] : a, b \in \mathbb{R}, a < b\}.$$

称 $\sigma(\mathcal{C})$ 为 $\mathbb{R}$ 上的Borel  $\sigma$ -代数，记为 $\mathcal{B}(\mathbb{R})$ ，其中的元素称为Borel集。事实上，对于左闭右开区间组成的集合族、开区间组成的集合族以及闭区间组成的集合族都生成 $\mathcal{B}(\mathbb{R})$ 。

# 目录

1 课程概况

2 概率空间

**3 随机变量**

4 数学期望

5 一些概率工具：矩母函数、概率不等式、极限定理

6 随机过程

# 随机变量

现实中，随机现象纷繁复杂，相应的样本空间千差万别。有些可以用数来表示，比如测量误差，有些则不行，比如掷一枚硬币。我们希望能将这些试验结果用“数”来表示，最简单的办法就是把样本点映射到一个数上，即  $\xi : \Omega \rightarrow \mathbb{R}$ 。但是我们知道，描述事件时需要明确所对应的事件域，这引入了随机变量的概念。

## 定义 6 (随机变量 Random variable)

给定概率空间  $(\Omega, \mathcal{F}, P)$ ，**随机变量 (random variable, r.v.)** 是一个函数  $X : \Omega \rightarrow \mathbb{R}$  满足：对于所有的  $B \in \mathcal{B}(\mathbb{R})$ ， $\{\omega : X(\omega) \in B\} \in \mathcal{F}$ 。

测度论中，这样的函数称为可测函数(measurable function)。



# 分布

## 定义 7 (概率分布Probability distribution)

设  $X$  是概率空间  $(\Omega, \mathcal{F}, P)$  上的随机变量,  $\mathcal{B}(\mathbb{R})$  上的概率测度

$$P_X : \mathcal{B}(\mathbb{R}) \rightarrow [0, 1], \quad P_X(A) := P \circ X^{-1}(A), \quad \forall A \in \mathcal{B}(\mathbb{R}).$$

称为  $X$  的**概率分布** (*probability distribution*).

若两个随机变量  $X$  和  $Y$  具有相同的概率分布, 则称  $X$  和  $Y$  是同分布的。  $X$  和  $Y$  可以是两个不同概率空间上的随机变量, 但它们可以有相同的分布。

# 分布函数

## 定义 8 (分布函数)

对于任意  $x \in \mathbb{R}$ , 随机变量  $X$  的分布函数 (*distribution function*) 定义为

$$F(x) = P(X \leq x) = P(\{\omega; X(\omega) \in (-\infty, x]\}), \quad \bar{F}(x) = 1 - F(x) = P(X > x).$$

如果一个随机变量  $X$  可能值的集合是可数的, 则称它是离散随机变量, 它的分布函数为

$$F(x) = \sum_{y \leq x} P(X = y).$$

如果存在一个函数  $f(x)$  (称为概率密度函数, probability density function, pdf), 使得对于任意 (Borel) 集合  $B \subset \mathbb{R}$

$$P(X \in B) = \int_B f(x) dx,$$

则称随机变量  $X$  是连续的。

## 联合分布

两个随机变量 $X$ 和 $Y$ 的联合分布函数定义为

$$F(x, y) = P(X \leq x, Y \leq y)$$

$X$ 和 $Y$ 的分布函数分别为

$$F_X(x) = P(X \leq x) = \lim_{y \rightarrow \infty} P(X \leq x, Y \leq y) = \lim_{y \rightarrow \infty} F(x, y).$$

$$F_Y(y) = P(Y \leq y) = \lim_{x \rightarrow \infty} F(x, y).$$

如果存在一个函数 $f(x, y)$ , 使得对于任何(Borel)集合 $A$ 和 $B$ , 有

$$P(X \in A, Y \in B) = \int_A \int_B f(x, y) dy dx$$

则称随机变量 $X$ 和 $Y$ 是联合连续的(Jointly continuous),  $f(x, y)$ 称为联合密度函数。

# 独立性

## 定义 9 (独立)

如果对于一切  $x, y$ , 有

$$F(x, y) = F_X(x)F_Y(y)$$

则称随机变量  $X$  和  $Y$  是独立的。

更一般地, 任意一族随机变量  $X_1, X_2, \dots, X_n$  的联合分布定义为

$$F(x_1, \dots, x_n) = P(X_1 \leq x_1, \dots, X_n \leq x_n).$$

对于  $1 \leq i \leq n$ , 边缘分布为

$$F_{X_i}(x_i) = \lim_{x_j \rightarrow \infty, j \neq i} F(x_1, x_2, \dots, x_n).$$

称  $X_1, X_2, \dots, X_n$  是独立的, 如果

$$F(x_1, \dots, x_n) = F_{X_1}(x_1) \cdots F_{X_n}(x_n).$$

# 目录

1 课程概况

2 概率空间

3 随机变量

**4 数学期望**

5 一些概率工具：矩母函数、概率不等式、极限定理

6 随机过程

# 期望

## 定义 10 (期望)

随机变量  $X$  的期望  $\mathbb{E}[X]$  定义为:

$$\mathbb{E}[X] = \int_{-\infty}^{\infty} x dF(x) = \begin{cases} \sum_x x P(X = x) & \text{若 } X \text{ 是离散的.} \\ \int_{-\infty}^{\infty} x f(x) dx & \text{若 } X \text{ 是连续的.} \end{cases}$$

如果此积分存在。

对于  $X$  的任意函数  $h$ ,  $h(X)$  的期望为

$$\mathbb{E}[h(X)] = \int_{-\infty}^{\infty} h(x) dF(x)$$

## 命题 4

$$\mathbb{E} \left[ \sum_{i=1}^n X_i \right] = \sum_{i=1}^n \mathbb{E}[X_i]$$

# 方差

## 定义 11 (方差/协方差)

随机变量 $X$ 的方差 $Var[X]$ 定义为:

$$Var[X] = \mathbb{E}[(X - \mathbb{E}X)^2] = \mathbb{E}[X^2] - (\mathbb{E}[X])^2$$

两个联合地分布的随机变量 $X$ 和 $Y$ 的协方差定义为

$$Cov(X, Y) = \mathbb{E}[(X - \mathbb{E}[X])(Y - \mathbb{E}[Y])] = \mathbb{E}[XY] - \mathbb{E}[X]\mathbb{E}[Y].$$

若 $Cov(X, Y) = 0$ , 我们称 $X$ 和 $Y$ 不相关(uncorrelated)。所以 $X$ 和 $Y$ 独立 $\Rightarrow X$ 和 $Y$ 不相关, 但反过来不一定正确。

## 命题 5

$$Var\left[\sum_{i=1}^n X_i\right] = \sum_{i=1}^n Var[X_i] + 2\sum_{i < j} Cov(X_i, X_j)$$

# 组合数学中的概率方法

开创概率方法<sup>2</sup>的数学大师：Paul Erdős




<sup>2</sup>感兴趣可参考专著：Alon N, Spencer J H. The probabilistic method[M]. John Wiley & Sons, 2016.



## 例：组合数学中的概率方法

图(graph)  $G = (V, E)$ 由节点(node)集合 $V$ 和连边(edge)集合 $E$ 组成。例如下图中，

$$V = \{1, 2, 3, 4, 5\}, \quad E = \{(1, 2), (1, 3), (1, 5), (2, 3), (2, 4), (3, 4), (3, 5)\}$$



证明：对于任何一个图，一定存在节点集的一个子集 $A$ ，使得至少有一半的边，它的一个节点在 $A$ 中，而另一个在 $A^c$ 中。例如上图中 $A = \{1, 2, 4\}$ 。

**Proof.**

转化为数学语言：设一个图有 $m$ 条边，分别记为 $1, 2, \dots, m$ 。对于任意节点集合 $B$ ，恰有一个节点在 $B$ 中的连边的个数记为 $C(B)$ ，那么我们即是要证明：

$$\max_B C(B) \geq \frac{m}{2}.$$

概率建模：随机选取一个节点集合 $S$ ，使得这个图的任意节点都独立地以概率 $1/2$ 在 $S$ 中。记随机变量 $X$ 为：恰有一个节点在 $S$ 中的连边的个数，它可能的取值是 $C(B)$ 所有可能值的集合。

对于连边 $i \in \{1, \dots, m\}$ ，如果恰有一个节点在 $S$ 中，就令 $X_i = 1$ ，否则 $X_i = 0$ ，那么

$$\mathbb{E}[X] = \mathbb{E}\left[\sum_{i=1}^m X_i\right] = \sum_{i=1}^m \mathbb{E}[X_i] = \frac{m}{2}.$$

由于随机变量至少有一个值和它的均值一样大，所以至少有一个节点集合 $B$ 满足

$$C(B) \geq \frac{m}{2}.$$



## 条件期望

对于离散随机变量  $X, Y$ , 对所有  $y$  满足  $P(Y = y) > 0$ ,  
给定  $Y = y$ ,  $X$  的条件概率质量函数(conditional probability mass function) 定义为

$$P(X = x|Y = y) = \frac{P(X = x, Y = y)}{P(Y = y)}.$$

给定  $Y = y$ ,  $X$  的条件分布函数(Conditional distribution function) 定义为

$$F(x|y) = P(X \leq x|Y = y) = \sum_{z \leq x} P(X = z|Y = y).$$

给定  $Y = y$ ,  $X$  的条件期望定义为

$$\mathbb{E}[X|Y = y] = \int x dF(x|y) = \sum_{x \in S} x P(X = x|Y = y).$$

## 条件期望

如果  $X, Y$  有联合密度函数  $f(x, y)$ , 对所有  $y$  满足  $f_Y(y) = \int f(x, y)dx > 0$ ,  
给定  $Y = y$ ,  $X$  的条件概率密度函数(conditional probability density function) 定义为

$$f(x|y) = \frac{f(x, y)}{f_Y(y)}.$$

给定  $Y = y$ ,  $X$  的条件分布函数(Conditional distribution function)定义为

$$F(x|y) = \mathbb{P}(X \leq x|Y = y) = \int_{-\infty}^x f(z|y)dz.$$

给定  $Y = y$ ,  $X$  的条件期望定义为

$$\mathbb{E}[X|Y = y] = \int_{-\infty}^{\infty} xf(x|y)dx.$$

# 条件期望

## 命题 6

记 $\mathbb{E}[X|Y]$ 为随机变量 $Y$ 的函数：它在 $Y = y$ 处取值 $\mathbb{E}[X|Y = y]$ 。当天件期望存在时，对于一切随机变量 $X$ 和 $Y$ 有

$$\mathbb{E}[X] = \mathbb{E}[\mathbb{E}[X|Y]] = \int \mathbb{E}[X|Y = y] dF_Y(y)$$

注. 初等概率论中的条件概率和条件期望不严格性

- 在初等定义中，要求 $P(Y = y) > 0$ ，实际中会遇到概率为0的情况，比如连续空间中单点的概率；
- 初等定义中的条件期望通常基于具体的条件值（ $Y = y$ ），但在更一般的条件下，我们需要定义一个更一般的条件期望，能够处理更复杂的条件信息，如 $\sigma$ -代数。

## 条件期望与Bayes估计

在Bayes统计中，我们认为观测数据 $X = (X_1, \dots, X_n)$ 的分布由一个随机变量 $\theta$ 确定， $\theta$ 服从一个概率分布，我们称为先验分布(prior distribution)。

$\theta$ 的一个估计 $d(X)$ 是观察数据 $X$ 的任意函数，Bayes统计中通常选择 $d(X)$ 使得条件均方误差

$$\mathbb{E}[(\theta - d(X))^2 | X]$$

达到最小。

可以证明<sup>3</sup>，使得 $\mathbb{E}[(\theta - d(X))^2 | X]$ 达到最小的估计为


$$d(X) = \mathbb{E}[\theta | X]$$

称为Bayes估计。

---

<sup>3</sup>参阅教材1.5节

## Bayes观点



# 目录

1 课程概况

2 概率空间

3 随机变量

4 数学期望

**5 一些概率工具：矩母函数、概率不等式、极限定理**

6 随机过程



# 矩母函数

## 定义 12 (矩母函数)

随机变量  $X$  的矩母函数 (*moment generating function*) 定义为

$$\psi(t) = \mathbb{E}[e^{tX}] = \int e^{tx} dF(x).$$

可以通过对矩母函数  $\psi$  求各阶导得到  $X$  的各阶矩

$$\psi(0) = 1, \psi'(0) = \mathbb{E}[X], \psi''(0) = \mathbb{E}[X^2], \dots, \psi^{(n)}(0) = \mathbb{E}[X^n].$$

注. 当矩母函数存在时, 它唯一地确定分布。

离散概率分布 <sup>4</sup>	概率质量函数 $p(x)$	矩母函数 $\psi(t)$	均值	方差
<b>二项分布</b> 参数 $n, p, 0 \leq p \leq 1$	$\binom{n}{x} p^x (1-p)^{n-x}$ $x = 0, 1, \dots, n$	$[pe^t + (1-p)]^n$	$np$	$np(1-p)$
<b>泊松分布</b> 参数 $\lambda > 0$	$e^{-\lambda} \frac{\lambda^x}{x!}$ $x = 0, 1, 2, \dots$	$\exp\{\lambda(e^t - 1)\}$	$\lambda$	$\lambda$
<b>几何分布</b> 参数 $0 \leq p \leq 1$	$p(1-p)^{x-1}$ $x = 1, 2, \dots$	$\frac{pe^t}{1-(1-p)e^t}$	$\frac{1}{p}$	$\frac{1-p}{p^2}$
<b>负二项分布</b> 参数 $r, p$	$\binom{x-1}{r-1} p^r (1-p)^{x-r}$ $x = r, r+1, \dots$	$\left[ \frac{pe^t}{1-(1-p)e^t} \right]^r$	$\frac{r}{p}$	$\frac{r(1-p)}{p^2}$

<sup>4</sup>连续概率分布参考教材表1.4.2

## 特征函数

由于随机变量的矩母函数可能不存在，注意到 $|e^{itX}| = 1$ ，在理论上考虑下面特征函数更为方便。

### 定义 13

随机变量 $X$ 的特征函数(*characteristic function*)定义为

$$\varphi(t) = \mathbb{E}[e^{itX}].$$

更一般地，随机变量 $X_1, X_2, \dots, X_n$ 的联合矩母函数为

$$\psi(t_1, \dots, t_n) = \mathbb{E}[\exp(\sum_{i=1}^n t_i X_i)],$$

以及联合特征函数为

$$\varphi(t_1, \dots, t_n) = \mathbb{E}[\exp(i \sum_{i=1}^n t_i X_i)].$$

# Markov不等式

## 引理 1 (Markov不等式)

设  $X$  是一个非负随机变量, 那么对于任意  $a > 0$ , 有

$$\mathbb{P}(X \geq a) \leq \frac{\mathbb{E}[X]}{a}$$

## 推论 1 (切比雪夫不等式)

设  $X$  是一个随机变量, 且均值  $\mu$  和方差  $\sigma^2$  有限, 则对任何  $k > 0$ , 有

$$P\{|X - \mu| \geq k\} \leq \frac{\sigma^2}{k^2}$$

## Chernoff界

## 命题 7 (Chernoff 界)

设  $X$  是一个随机变量，其矩母函数为  $\psi(t) = \mathbb{E}[e^{tX}]$ ，那么对于  $a > 0$ ,

$$\mathbb{P}(X \geq a) \leq e^{-ta}\psi(t), \text{ for } t > 0;$$

$$\mathbb{P}(X \leq a) \leq e^{-ta}\psi(t), \text{ for } t < 0.$$

**Proof.**

对于  $t > 0$ ,

$$\mathbb{P}(X \geq a) = \mathbb{P}(e^{tX} \geq e^{ta}) \stackrel{\text{Markov}}{\leq} \mathbb{E}[e^{tX}]e^{-ta}.$$

$t < 0$  同理可证。



# Jensen不等式

## 命题 8 (Jensen不等式)

如果  $f$  是一个凸函数, 即

$$\lambda f(x) + (1 - \lambda)f(y) \geq f(\lambda x + (1 - \lambda)y), \forall \lambda \in (0, 1), x, y \in \mathbb{R}.$$

那么只要期望存在, 就有

$$\mathbb{E}[f(X)] \geq f(\mathbb{E}[X])$$

$f(x) = |x|$ 是凸的, 于是

$$|\mathbb{E}[X]| \leq \mathbb{E}[|X|]$$

$f(x) = x^2$ 是凸的, 于是

$$(\mathbb{E}[X])^2 \leq \mathbb{E}[X^2]$$

## 随机变量的收敛

设 $(\Omega, \mathcal{F}, P)$ 为一个概率空间,  $(X_n)$ 为 $(\Omega, \mathcal{F}, P)$ 上随机变量序列。

(1) **依概率收敛** Convergence in probability: 记为 $X_n \xrightarrow{P} X$ , 如果对于 $\epsilon > 0$

$$P(\omega : |X_n(\omega) - X(\omega)| > \epsilon) \rightarrow 0, n \rightarrow \infty.$$

(2) **几乎处处收敛** Almost sure convergence: 记为 $X_n \rightarrow X, a.s.$ , 如果

$$P(\omega : \lim_{n \rightarrow \infty} X_n(\omega) = X(\omega)) = 1.$$

(3) **依分布收敛** Convergence in distribution: 记为 $X_n \xrightarrow{d} X$ , 如果对于任意有界连续函数 $f$

$$\int f dP_{X_n} \rightarrow \int f dP_X,$$

(4)  **$L^p$ 收敛** Convergence in  $L^p$ : 记为 $X_n \xrightarrow{L^p} X$ , 如果

$$\|X_n - X\|_p = (\mathbb{E}|X_n - X|^p)^{1/p} \rightarrow 0.$$

# 极限定理

## 定理 1 (弱大数定律)

设  $X_1, X_2, \dots$  独立同分布且公共期望  $\mu = \mathbb{E}[X_i] < \infty$ , 则对任意  $\varepsilon > 0$ ,

$$\lim_{n \rightarrow \infty} \mathbb{P} \left( \left| \frac{X_1 + \dots + X_n}{n} - \mu \right| > \varepsilon \right) = 0. \text{ convergence in probability}$$

## 定理 2 (强大数定律)

设  $X_1, X_2, \dots$  独立同分布且公共期望  $\mu = \mathbb{E}[X_i] < \infty$ , 则

$$\mathbb{P} \left( \lim_{n \rightarrow \infty} \frac{X_1 + \dots + X_n}{n} = \mu \right) = 1. \text{ a.s. convergence}$$

## 定理 3 (中心极限定理)

设  $X_1, X_2, \dots$  独立同分布, 且均值为  $\mu$ , 方差为  $\sigma^2$ , 则对任意  $a$ ,

$$\lim_{n \rightarrow \infty} \mathbb{P} \left( \frac{X_1 + \dots + X_n - n\mu}{\sigma\sqrt{n}} \leq a \right) = \int_{-\infty}^a \frac{1}{\sqrt{2\pi}} e^{-\frac{x^2}{2}} dx. \text{ convergence in distribution}$$



# 目录

- ① 课程概况
- ② 概率空间
- ③ 随机变量
- ④ 数学期望
- ⑤ 一些概率工具：矩母函数、概率不等式、极限定理
- ⑥ 随机过程**

# 基本概念

## 固定 $t$

### 定义 14 (随机过程)

设 $(\Omega, \mathcal{F}, P)$ 为概率空间,  $(E, \mathcal{E})$ 为可测空间, 指标集  $T \subset \mathbb{R}$ , 若对任何  $t \in T$ ,

$$X_t : \Omega \mapsto E,$$

可测, 则称 $\{X_t : t \in T\}$ 是 $(\Omega, \mathcal{F}, P)$ 上的取值于 $E$ 的随机过程, 称 $(E, \mathcal{E})$ 为其“相空间”或“状态空间”, 称 $T$ 为其“时间域”。

简单来说, 随机过程 $\{X_t(\omega) : t \in T\}$ 是一族随机变量, 若指标集 $T$ 是可数集, 则我们称 $\{X_t\}$ 为离散时间的随机过程, 若 $T$ 是连续统, 则称 $\{X_t\}$ 为连续时间的随机过程。

# 基本概念

## 固定 $\omega$

定义 15 (样本轨道 Sample path)

设 $\{X_t : t \in T\}$ 是一个取值于 $E$ 的随机过程。 $X$  的样本轨道定义为在固定 $\omega \in \Omega$ 情况下的映射

$$T \ni t \mapsto X_t(\omega)$$

也就是说,  $X$ 的样本轨道是那些由 $\omega \in \Omega$ 索引的, 从时间集合 $T$ 到状态空间 $E$ 的映射的集合

$$\{t \mapsto X_\omega(t)\}_{\omega \in \Omega}$$

# 本课程内容

- 离散时间离散状态的随机过程：Markov链；
- 连续时间离散状态的随机过程：跳过程 (Poisson过程、连续时间Markov链)；
- 连续时间连续状态的随机过程：Markov过程。